

基于 SIFT 特征和残差网络的手型和掌纹识别

张艺驰

(中央民族大学 信息工程学院, 北京市 100081)

摘要: 近年来, 掌纹识别作为一项“年轻”的生物识别技术应运而生。每个人的掌纹都包含丰富的个体身份信息, 其特征较稳定且唯一, 抗噪声干扰能力强。本文对采集到的手部图像数据集进行预处理操作, 基于 SVM 算法进行手型识别和性别, 通过对比三种典型的 SVM 算法选出最优方法和参数。此外针对原始数据集进行数据增强和预处理, 采用尺度不变特征提取算法对掌纹进行特征提取, 基于残差网络进行掌纹识别, 实验结果表明该方法取得了一定成果。

关键词: 掌纹识别; 手型识别; SIFT; 残差网络; SVM

中图分类号: TP391

文献标识码: A

Hand Shape and Palmprint Recognition Based on SIFT Feature and Residual Network

YiChi Zhang

(College of Information Engineering, Minzu University of China, Beijing 100081, China)

Abstract : In recent years, palm print recognition has emerged as a "young" biometric technology. Each person's palm print contains rich personal identity information, its characteristics are stable and unique, and the ability to resist noise interference is strong. In this paper, the collected hand image dataset is preprocessed, hand pattern recognition and gender are performed based on SVM algorithm, and the optimal method and parameters are selected by comparing three typical SVM algorithms. In addition, the data enhancement and preprocessing of the original dataset are carried out, the scale invariant feature extraction algorithm is used to extract the features of palmprint, and the palmprint recognition is carried out based on the residual network, and the experimental results show that the proposed method has achieved certain results.

Key words: Palmprint recognition; Hand recognition; SIFT; Residual network; SVM

0 引言

随着计算机网络通信和电子商务技术的迅猛发展, 如何准确、快速认证用户身份成为了当今社会的热点问题。传统基于密码、口令的身份认证方法由于存在易丢失、易伪造等缺点, 已逐渐被生物识别技术所

代替。近年来, 掌纹识别技术作为一种新兴的生物特征识别技术, 因其所利用的掌纹具有特征信息丰富、防伪性能出色的优点, 受到了科研人员的广泛关注。

传统的掌纹识别技术多是围绕二维掌纹所展开, 但对于 1 种三维特征, 二维掌纹会因缺失一维信息影响最终的识别效果, 所以三维掌纹识别技术应运而生。Li W 等人^[1]

设计了一种基于结构光的设备来捕获手掌的三维数据,并进一步建立了由 8 000 个三维掌纹样本组成的数据库。在此基础上,研究者们进行了一系列与三维掌纹识别相关的研究工作。Zhang D 等人^[2]提出了一种三维掌纹识别方法,基于曲率对三维掌纹数据进行特征提取以获得平均曲率图像、高斯曲率图像和曲面类型(surface type, ST),再编码为二进制特征。白雪飞等人^[3]提出了一种新的三维掌纹识别方法,将分块曲面类型与主成分分析相结合以提升算法效率。但传统的三维掌纹识别技术分为“特征提取”与“特征匹配”2 个步骤。在识别过程中,不仅要选取特征提取时的滤波器,还要选取特征匹配时的分类器,因此增加了不同方法在优化组合时的难度。

近几年,深度学习在计算机视觉尤其是在样本识别领域内经历了飞速的发展。与传统的识别算法不同,深度学习可通过卷积神经网络同时完成特征的提取和分类。将深度学习运用到掌纹识别中也成为了当下学者们重点研究的一个方向。

1 相关研究

本文的主要研究对象为手的手形特征和掌纹区域的纹理特征,通过检索文献对近年来手形识别和掌纹识别的主要研究成果和学术动态进行整理。

1.1 手型识别发展动态

查阅文献发现,国内外对于手形的研究曾取得了很多优秀成果。苑玮琦^[4]于 2009 年发表了论文,在手掌形状为基础上根据手指长度的可测量性,提出了基于手指相对长度的手形识别方法,并在文中证明了以手形作为识别基础的可行性。同年又分

析了手指宽度的选取与识别率的对应关系,提出了利用曲率法定位特征点测量手指宽度的方法,并用相对宽度构建特征向量,通过计算特征向量的欧式距离实现了身份识别的算法^[5]。进一步确定了手指宽度作为身份特征的可行性。

近些年,由于基于体型庞大 PC 机作为生物特征识别有着一定的局限性,高雷^[6]设计了一套基于高性能数字图像处理芯片的手形识别系统。在识别过程中手形定位的准确度对识别精度影响较大,为了提高手形的定位精度,提出了首先寻找手指中线后对手形进行定位的方法,提高了手形识别的准确率和稳定性。随着计算技术的不断发展,研究人员在手形识别上结合不同的计算技术,进一步提高了手形的识别的准确率。李天宇^[7]在手形识别中首次使用了演进算法技术中的微粒群算法优化识别方法求解,该算法使用手指轮廓特征与几何特征相融合采用粒子群算法进行优化,进一步的提高了手形识别的准确率和识别算法的鲁棒性;李温温^[8]针对以非接触方式采集手形时,手掌根处的轮廓因手掌的张合程度不同而出现变形,从而导致手形的定位与识别出现偏差的问题,提出了在细化手指骨基础上拟合手指中线提取指形的方法,使得在非接触条件下提取精确手形的准确度提高。为了进一步提高手形提取的准确性,降低手掌摆放对手形提取的影响,李洋^[9]提出了基于手形图像分离五指后根据手掌中轴线重合注册手指,通过比较重合手指面积实现身份识别的方法。

相比与国内对手形的研究,国外很多研究者也为手形识别的研究做出了较多贡献。Travieso 和 Briceño^[10]对手形轮廓的马尔可夫链描述符的角度进行编码,并应用离散隐马尔可夫模型为内核的支持向量机对手

形编码进行分类的方法,取得了较高的正确率。

为在深度信息图像下识别非限制空间中的手形,James^[11]通过使用主成分分析来估计空间中的手部方向,使用 Flusser 矩不变量作为图像特征并使用两个 SVM-RBF 分类器进行识别。Nhu-Tai^[12]通过带有深度信息的图像对手掌骨骼进行建模,使用多级特征的长短期记忆网络提出了新的手形特征进行识别方法,为手形识别的研究提供了新的思路。

国内外对于手形识别的研究相对较少,通常手形特征作为一种简单易得的生物特征常结合其他手部生物特征互补特征出现在识别系统中。

1.2 掌纹识别发展动态

相比于手形识别的研究,掌纹识别一直作为研究热点活跃在生物识别研究领域。在掌纹识别领域中较为著名的 PolyU 掌纹数据库由香港理工大学在 2009 年首次通过其官方网站开源,该数据库的开源为掌纹识别研究者提供了统一的研究数据,促使了掌纹研究者对掌纹识别算法精度的不断提升。其中有着较多代表性的识别算法不断被提出。在早期的研究中,研究者主要通过对掌纹特征进行特征编码的方式通过评估编码实现对掌纹的识别。林森^[13]通过对掌纹图像的二进制鲁棒不变尺度特征对掌纹进行识别,构建的识别方法在识别速度和准确度上相比于之前的识别方法有了较大提升;早期的掌纹识别特征常以为掌纹主线作为识别特征,针对掌纹主线的特征提取算法虽然可以获得主线的大致位置,但会丢失大部分手掌纹理信息。为更好的提取掌纹的低维分类特征,张善文^[14]针对

掌纹丰富的纹理特征特点,提出了一种基于加权自适应中心对称的局部二值模式(WACS-LBP)与局部判别映射(LDP)相结合的掌纹识别方法,该方法提取出的低维度掌纹特征应用简单的分类模型即可得到较高的识别正确率。早期对掌纹研究的采集方式多为接触式,考虑在应用中接触式采集掌纹存在一定的公共卫生隐患,逐渐有研究者展开了对非接触式采集掌纹图像的研究。在非接触式的掌纹图像采集时,由于掌纹区域相对于采集设备距离不固定产生离焦模糊问题,林森^[15]构建了模拟离焦模糊条件下掌纹图像数据集,并使用拉普拉斯平滑变换提取了掌纹的低频特征用作识别特征,较好地解决了离焦模糊所导致的掌纹识别准确率下降的问题。

随着掌纹研究的不断深入,掌纹识别所面对的数据量也在不断增大,为识别算法准确度和识别速度的进一步提升提出了较大的挑战。为了在大量的掌纹数据库中构建更加快速、准确的掌纹识别系统,陈曦^[16]提出了一种基于局部方向散列的快速掌纹识别方法。该方法采用了基于方向特征的双编码方式,对比于传统的方向特征编码该方法有效的解决了编码稳定性较差的问题,在此基础上又提出了特征窗口化处理方式,进一步减少了在掌纹匹配检索上的耗时,该方法在各大开源的掌纹数据库中有着很好的正确率和识别速度的表现。

掌纹区域分割是掌纹识别过程中重要的一个环节,常用的掌纹区域分割方法多是基于手掌几何形状的特征点定位,依据掌纹区域与特征点的几何位置关系对掌纹区域进行划分。为了改善掌纹特征区域提取特征点的偏差所造成的提取的掌纹区域偏移的问题,张秀峰^[17]等提出了一种新的掌纹区域划分方法,该方法先确定手掌图像

中两个手指谷点;然后利用手掌轮廓区域边界点来拟合直线,以该直线为基准,使用固定角度的方式建立直角坐标系,利用谷点信息找到掌纹信息丰富的区域,从而确定掌纹区域。经实验对比,该方法对掌纹区域提取的准确度高、速度快。

近年来深度学习的研究逐渐火热,一些研究人员也开始使用深度学习网络对掌纹识别开展研究。郑仕伟^[18]较早的使用卷积神经网络对掌纹特征进行提取并通过分类器得到掌纹识别方法,该方法相比于基于编码方式对掌纹图像进行特征提取的方法降低了光照和摆放姿势对掌纹识别的影响,同时取得了较高的识别准确率。陈杰^[19]等通过在掌纹识别的卷积神经网络中引入最大池化操作,并使用 Softmax 分类器作为输出层级达到了对掌纹的特征提取和识别结果输出的效果。

在国外,研究人员对掌纹识别的研究也做出了较多的贡献。随着手机等移动通讯设备的不断普及,为了拓展掌纹识别的应用场景,在移动设备作为图像采集条件下的掌纹识别研究逐渐引起了研究者的关注。Adrian-Stefan^[20]首次构建了应用手机作为图像采集设备的掌纹数据库,针对不同型号手机在不同背景环境下采集到的掌纹图像提出了在非限制条件下基于手指中线特征点划分出的掌纹识别区域方法。为在移动设备非接触条件下掌纹识别的研究提供了新的思路。由于在手机等移动设备上拍摄的掌纹照片的清晰度不同,且这种清晰度的差异会影响掌纹识别的准确度,追求更高清晰度下的掌纹图像识别势必会增加采集设备的成本。Kunai^[21]基于边缘锐度值建立了一种清晰度评估模型,提出了计算最佳清晰度范围的方法。并给出了该计算方法在各大开源掌纹数据库中得出的结果,

为掌纹采集清晰度的最佳范围提供了有效的计算方法。

随着移动设备的计算能力和系统功能的不断增强,使得深度学习模型在移动设备上的部署应用成为可能,不断有研究者结合了轻量级的神经网络对掌纹识别算法展开了研究。Michele 和 Colin^[22]首次在掌纹识别中使用了可以流畅在手机等移动设备部署的轻量级神经网络 MobileNet 对掌纹进行了特征提取,并使用支持向量机来对提取到的掌纹特征做分类,得到的掌纹识别算法在多个开源掌纹数据库上取得了较好的正确率。同时使用的 MobileNet 神经网络所需参数量较少,识别运算所需计算量较小,便于在小型设备上应用。为进一步提升应用神经网络进行掌纹识别的准确度,同时改进多数神经网络忽略的掌纹在全局特征空间中的分布信息导致的严重局部性和不平衡性,Jinsong^[23]在掌纹识别领域首次提出了一种对抗性度量学习方法,使不同类别的掌纹均匀分散地分布在超球体特征空间中。该算法全面的利用了掌纹的整体特征,并在其构建的非限制性掌纹数据库中相比于以往的识别算法在准确率上提升了 4%,识别性能上提升了 15%。

随着掌纹识别研究的不断发展,越来越多的掌纹识别技术层出不穷。到目前为止国内外仍有大量研究人员为掌纹识别技术的进一步发展持续努力着,掌纹识别的应用范围也随着技术的成熟逐渐扩大。

2 相关理论

在手型识别任务中使用到的 SVM 算法和在掌纹识别任务用到的 SIFT 特征提取方法以及残差网络的基本原理在本节进行介

绍。

2.1 SVM 算法

在手形识别中, 假设手形的 n 个相对坐标数据为手形分类的数据属性, 以全部手形分类中的 m 个手形作为训练集合, 存在某个超平面 (w, b) 可以将所有数据属性向量正确分类。使用向量 $(x_{1j}, \dots, x_{ij}, \dots, x_{nj}) (j = 1, 2, \dots, m)$ 来表示第 j 个手的 n 个数据特征, 对于 $(x_{1j}, \dots, x_{ij}, \dots, x_{nj}) \in D$, 可以设 $y_i = +1$ 表示手形属于同一个类别, 则有 $W^T x_i + b > 0$; 同时设 $y_i = -1$ 表示手形属于不同的类别, 则有 $W^T x_i + b < 0$ 。可由式(1)表示。

$$\begin{cases} W^T x_i + b \geq +1, & y_i = +1 \\ W^T x_i + b \leq -1, & y_i = -1 \end{cases} \quad (1)$$

其中 D 为训练数据的集合。

由上易得, 两个不同分类向量和可由式(2)计算。

$$\gamma = \frac{2}{\|w\|} \quad (2)$$

计算不同类间最大间隔的超平面表达式满足式(3)。

$$\max \frac{2}{\|w\|} w, b \quad (3)$$

$$\text{s.t. } y_i(W^T x_i + b) \geq +1, i = 1, 2, \dots, m \quad (4)$$

公式(4)即为支持向量机的基本型。

可见支持向量机的基本型即是限制条件下分类问题的最优解, 在实现该算法时通常是求得支持向量机基本型的拉格朗日法的等价问题。

2.2 SIFT 特征

尺度不变特征变换 (Scale Invariant Feature Transform, SIFT) 算法是当今图像处理中使用最广泛的算法。改变原始图像尺度可以获得表示多个尺度图像的尺度空间序列, 并从序列中提取尺度空间的主轮廓。主轮廓用作特征向量来提取特征并检测不同分辨率的角点。图像的尺度空间可

以定义为:

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y) \quad (5)$$

式中: $I(x, y)$ 是原始图像; $G(x, y, \sigma)$ 是高斯函数; σ 表示空间的大小, σ 越大表明越模糊, σ 越小表示越清晰。高斯函数 $G(x, y, \sigma)$ 为:

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (6)$$

SIFT 算法中使用 DOG 函数 $D(x, y, \sigma)$ 来找到极值点, 定义为:

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma) \quad (7)$$

DOG 对噪声和边缘很敏感, 因此, 需拟合 DOG 空间以找到极值点的位置和比例。由于图像中物体边缘位置点的主曲率一般较高, 因此由主曲率判断该点是否位于物体的边缘位置, 公式如下:

$$m(x, y) = \sqrt{\begin{pmatrix} (L(x+1, y) - L(x-1, y))^2 + \\ (L(x, y+1) - L(x, y-1))^2 \end{pmatrix}} \quad (8)$$

$$\theta(x, y) = \text{atan} \left(\frac{2 \cdot L(x, y+1) - L(x, y-1)}{(L(x+1, y) - L(x-1, y))} \right) \quad (9)$$

式中: $m(x, y)$ 是梯度幅值; $\theta(x, y)$ 是方向。

2.3 残差网络

2015 年, He 等^[24]在卷积神经网络的基础上, 提出了深度残差网络。在网络中使用了残差块结构, 即通过插入快捷链接将其转化为对应的残差版本, 其目的在于解决由于模型层数增加而导致的梯度弥散或梯度爆炸问题。

残差网络的基本思想是引入短路连接 (shortcut connection) 概念, 使其更容易被优化, 短路连接是一种跨越一层或多层的网络结构, 几个短路连接结构堆叠在一起形成残差学习单元, 如图 1。假设模型输入为 x , 原始映射是 $H(x)$, 把网络设计为 $H(x) = f(x) + x$, 得到一个残差映射 $f(x) + x$, 2种映射的表达效果相同, 但由于 $f(x)$ 的规模较小, 拟合 $f(x)$ 要比拟合 $H(x)$ 简单许

多. 将模型中的原始映射 $H(x)$ 全部替换为残差映射 $f(x) + x$, 可以降低网络模型的拟合难度. 残差学习单元如图 1 所示.




图 1 残差学习单元

残差学习单元的数学定义为:

$$y_i = f[x_i + R(x_i, w_i)] \quad (6)$$

其中, y_i 表示第 i 个残差学习单元的输出, x_i 表示残差单元的输入, f 是激活函数, $R(x_i, w_i)$ 表示残差, w_i 表示卷积核.

在残差学习单元中不包含池化层, 因此不进行池化操作, 特征图的大小是通过卷积操作来决定的. 在结构上, 残差学习单元采用“瓶颈”设计, 以减少模型的参数量、增加网络深度, 使模型具有更好的特征学习能力的同时降低计算的成本.“瓶颈”模块的使用对模型的最终精度没有影响.

3 手型识别

3.1 数据预处理

1、单手样本提取

数据集原始样图见图 2, 可以看到数据集中存在单手和双手两种类型的图片, 且图片中两只手方向相反, 在使用时需要提取单手图片, 直接使用会有很多噪声.




图 2 单手提取示例

因此, 我们需要把图片中手心向上的部分提取出来. 实验设计一个手部识别模块, 识别手的关节并编号, 根据返回的关节坐标数量判断单双手, 得到提取样本, 提取后的样本如图 3 所示.



图 3 数据集原图样例

2、关键点定位

实验使用手部识别模块检测所有手的列表, 对列表进行访问, 从而获得手的位置信息, 每一个标志位都有一个 id 获取并将其显示. 识别后分别计算关节距离和手指夹角, 计算关节间的距离, 共 15 个, 计算手指之间的夹角, 共 4 个, 数据存储在 excel 表中, 见图 4 所示.

C	D	E	F	G	H	I	J
0	0.631038	0.508231	0.441937	0.803731	0.293843	0.108541	1.0
0	0.899007	0.721237	0.572381	0.940510	0.610635	0.463543	1.0
0	0.425967	0.316656	0.134534	0.881894	0.373075	0.263804	1.0
0	0.487564	0.349872	0.133247	0.839273	0.382080	0.289556	1.0
0	0.875199	0.796428	0.672967	0.959242	0.500484	0.333991	1.0
0	0.972671	0.806812	0.652862	0.889230	0.479662	0.366039	1.0
0	0.529756	0.309909	0.214053	0.869135	0.411740	0.320393	1.0
0	0.659205	0.515136	0.517620	0.779006	0.499610	0.398080	0.941642
0	0.878808	0.788799	0.668635	0.925134	0.546652	0.392501	1.0
1	0.706319	0.624420	0.428328	0.819774	0.553548	0.402632	1.0
0	0.760512	0.659024	0.505928	0.852795	0.473531	0.389519	1.0
1	0.588425	0.412945	0.462071	0.825205	0.439542	0.370116	1.0

图 4 数据示例

3.2 模型训练与调整

实验共使用支持向量机 (SVM) 中典型的三个模型做对比实验, 分别是 SVC、NuSVC 和 LinearSVC, 并在同一模型中使用不同核函数再次比对。其中 SVC 和 NuSVC 是用一对一的方法进行多分类, 二者相仅仅在于对损失的度量方式不同。LinearSVC 则在线性核的基础上实现了 one vs rest 方式, 默认使用 L2 范数, 核函数是线性的, 不接受 kernel 参数。

由于算法的性能受参数的影响极大, 实验中需设置的参数有 SVM 的惩罚因子 C, 核函数 kernel, gamma 参数等, 对于不同的数据使用不同的参数, 结果效果可能差 1 到 5 个点。为提高算法性能, 实验借助 GridSearchCV (网格搜索) 对模型自动调参, 根据输入参数给出最优化的结果和参数。这种调参本质是一种贪心算法, 使用当前对模型影响最大的参数调优, 直到最优化, 将所有的参数调整完毕, 因此数据运算量大, 仅适用于小数据集, 可能会调到局部最优而不是全局最优。

此外, sklearn 也提供了专门调试参数的函数 Grid Search, 它是穷举搜索, 在所有候选的参数选择中, 通过循环遍历, 尝试每一种可能性, 将表现最好的参数作为最终结果。但这种方法耗时, 当超参数的数量增长时, 网格搜索的计算复杂度会呈现指数增长, 使用随机搜索。因此这种方法适用于参数量极少的超参数。网格搜索算法使用每组超参数训练模型并挑选验证集误差最小的超参数组合。

除此以外, SVC 模型使用惩罚系数进一步优化 linear 核函数, 惩罚系数指对分类错误的惩罚程度, C 值越高, 对错误分类的惩罚越大, 模型训练时的准确率就会提高。但若惩罚系数过高, 不仅增加了计算资源的消耗, 还可能导致模型过拟合, 泛化能力减弱。经过实验认为, C 值设置在 60 时最优。

3.3 实验结果与分析

3.3.1 数据集

实验使用老师提供数据集, 处理后共 585 张图片, 按照 8: 2 比例分为训练集和测试集, 由于数据量偏少, 做五折交叉验证进行测试。

3.3.2 评价指标

实验室用置信度, 准确率和召回率对性别预测的结果进行对比, 并使用 SVC 的惩罚系数进一步优化 linear 核函数, 使用置信度对民族预测结果进行评估。

准确率和召回率是被广泛使用的两个度量值, 用来评价结果的质量。其中准确率是预测正确数量数与被预测总数的比率; 召回率是指预测正确数量和数据集中所有图片的比率。置信度指总体参数值落在样本统计值某一区内的概率。

3.3.3 实验结果

为确定模型 SVC 中惩罚系数的参数值, 实验对比在性别预测任务中不同惩罚系数下的准确率和召回率, 结果如图 5 所示。

从图中可以看到, 随着惩罚系数的增大, 准确率和召回率都在增大, 这是因为对错误分类的惩罚增大, 分类器的效果变好。但到达一个临界点即 60 后, 准确率和召回率都在降低, 这说明模型过拟合, 泛化能力减弱。因此, 综合来看设定为 60 是最优的。




图 5 惩罚系数对比图

性别预测的结果如表 1 所示，可以看出模型 SCV 和 NuSVC 对比来看，模型 SVC 在使用核函数 RBF 时效果更好。接着将 SVC 与 LinearSVC 在使用相同核函数 Linear 时做对比，发现模型 LinearSVC 效果更好。

这是因为试验任务是性别预测，使用特征是关节距离和夹角大小，共 19 个，因此样本数和特征数都不大，问题并不复杂。因此线性分类器更适用于此，避免复杂计算和过拟合。除去线性分类器，高斯核函数也是很好的选择。因为使用高斯核函数映射后，不仅能够实现将原训练数据再高维空间中实现线性划分，而且计算方面不会有太大的消耗。

表 1 性别预测结果 (%)

Model	Kernel	Accuracy	Recall
SVC	Linear	0.97	0.95
NuSVC	RBF	0.98	0.95
LinearSVC	linear	0.99	0.96
SVC	poly	0.98	0.97
SVC	RBF	0.99	0.93
SVC	sigmoid	0.96	0.94

关于性别和民族预测的置信度见图 6 所示，从预测效果来看，区分度较好，预测结果与其他待选结果的区分度高，可以准确的进行手型识别后的预测工作。

```
预测性别 [1. 1.] 置信度 [[9.9999990e-01 1.0000001e-07]
[9.9999990e-01 1.0000001e-07]]
预测民族 [2. 2.] 置信度 [[2.36284413e-07 9.99999364e-01 9.99999653e-08
9.99999653e-08 9.99999653e-08]
[1.96606543e-07 9.99999403e-01 9.99999698e-08 9.99999698e-08
9.99999698e-08 9.99999698e-08]]
```

图 6 置信度结果

4 掌纹识别

4.1 数据预处理

1、手心样本提取

掌纹图片仅在手心向上的图片中存在，

因此，要在手形识别处理后的数据的基础上，取出手心向上的图片。实验根据手部识别模块返回的坐标，得到拇指的位置来判断手心是否向上。因为当手心朝上时，拇指通常位于其他四个手指的下方。

2、掌形提取

实验使用手部识别模块，对手掌的各个关节进行编号。如图 7(a)所示，把编号 0、1、2、5、9、13、17 对应的编号连接起来得到一只手的掌纹区域。处理后的数据集如图 7(b)所示。




图 7(a) 关节编号示例




图 6(b) 掌纹数据示例

3、数据增强

为了使所采集的掌纹图像能方便的对图像后续处理，实验将图片统一大小，并处理为二维灰度图像，使掌纹更清晰，并对图像进行归一化处理。由于本次找到的数据掌纹数据集较少，为了得到更好的训练效果，我们进行了掌纹数据的扩展，将一

个掌纹图片进行旋转、翻转、拉伸等操作进行数据增强。

4.2 模型训练与调整

实验基于残差网络模型 ResNet18 来构建网络, ResNet18 是一种深度卷积神经网络结构, 具有 18 层深度, 完全使用卷积层和全连接层构成。因为它具有相当深的深度, 因此可以预测更复杂的模式和特征。此外, 它可以有效利用较少的特征, 从而显著提升网络性能。而且, 它提供了良好的参数优化, 可以更有效地学习, 降低了训练时间, 提高了训练效率。

模型在 ResNet18 网络结构基础上做出如下调整。因为 ResNet18 模型最后的输出维度是 1000, 在这里通过将原全连接层的输入特征数量作为新的全连接层的输入维度, 并设置输出维度为 32 来调整模型以适应监督学习的任务。此外还添加了一个 dropout 层和 ReLU 激活函数来加强模型的泛化能力。

模型分别使用交叉熵损失函数和 Adam 优化器作为损失函数和优化器, 设置初始学习率为 $1e-3$ 。经反复调整, 最后在训练迭代 300 次时效果最好, 并保存最后十次训练的模型参数。

4.3 实验结果与分析

4.3.1 数据集

实验在手形识别处理后的数据集基础上再次处理, 共 585 张图片, 按照 6: 3: 1 比例分为训练集, 测试集和验证集。

4.3.2 评价指标

实验室用准确率做为评判标准, 通过计算预测正确数量数与被预测总数的比率评估模型性能。

4.3.3 实验结果

模型迭代 300 次训练, 最终识别 ID 的正确率达到 71%, 数值偏低有如下几个原因。

1、样本量偏少。因为使用的是深度神经网络模型, 因此需要大量数据训练得到最终结果, 本文仅有百余张图片, 远远不够训练。

2、每类样本数量少。该实验任务是识别图片 ID, 因此需要将图片按照 Id 分类, 但每个 ID 下, 仅有 10 余张图片, 并不足以让模型提取充分的特征。

3、掌纹信息难提取。由于手的相似性, 掌纹并不容易区分, 其次, 手掌纹路的清晰度受光强等多种因素影响, 本就不如手形明显, 信息记忆丢失, 因此训练效果不如手形。

4 总结

本文基于 SIFT 提取图片特征, 并使用 SVM 算法, 残差网络等多种方法借助手形和掌纹信息对性别、民族和身份等属性识别, 手形识别因每类样本下数量更多, 样本信息更易提取等原因, 效果更好, 这说明模型的选择和设计不仅要依据数据类型, 还要依据实验目的。通过实验结果, 也可以看出, 通过手形识别生物属性技术已经偏向熟练, 但掌纹识别还有极大的提升空间。

参考文献

- [1] LI W, ZHANG D, LU G, et al. A novel 3-D palmprint acquisition system [J]. IEEE Transactions on Systems, Man and Cybernetics, Part A: Systems and Humans, 2012, 42(2):443-452.
- [2] ZHANG D, LU G, LI W, et al. Three dimensional palmprint recognition using structured light imaging [C] // 2008 IEEE the Second International Conference on Biometrics:

- Theory, Applications and Systems, IEEE, 2008:1-6.
- [3] 白雪飞, 高楠, 张宗华, 等. 基于分块 ST 与主成分分析的三维掌纹识别 [J]. 天津大学学报(自然科学与工程技术版), 2018, 51(6):631-637.
- [4] 苑玮琦, 朱春艳, 柯丽. 手指宽度选取与识别率对应关系分析[J]. 光学精密工程, 2009, 17(07): 1730-1736.
- [5] 高雷. 基于 DSP 的手形识别系统研究[D]. 吉林: 吉林大学, 2015.
- [6] 刘富, 刘惠影, 李天宇. 基于手指融合特征和粒子群优化的手形识别[J]. 光学精密工程, 2015, 23(06): 1774-1782.
- [7] 李温温, 刘富, 高雷. 基于手指骨架提取的手形识别方法[J]. 中南大学学报(自然科学版), 2016, 47(03): 777-783.
- [8] 李洋, 刘富, 高雷. 基于手指轮廓的手形识别算法[J]. 智能系统学报, 2016, 11(01): 99-103.
- [9] Carlos M T, Juan C B, Jesús B A. Transformation of hand-shape features for a biometric identification approach[J]. Sensors, 2012, 12(1): 987-1001.
- [10] James J P, Antonio C, Hangbae C. Hand shape classification using depth data for unconstrained 3d interaction[J]. Journal of Ambient Intelligence and Smart Environments, 2014, 6(1): 93-105.
- [11] Do N T, Kim S H, Yang H J. Robust hand shape features for dynamic hand gesture recognition using multi-level feature lstm[J]. Applied Sciences-Basel, 2020, 10(18): 6293-6299.
- [12] 林森, 苑玮琦, 宋辉. 二进制鲁棒不变尺度特征在非接触掌纹识别中的应用[J]. 仪器仪表学报, 2013, 34(12): 2785-2792.
- [13] 张善文, 张晴晴, 齐国红. 加权自适应 CS-LBP 与局部判别映射相结合的掌纹识别方法[J]. 计算机应用研究, 2017, 34(11): 3482-3485.
- [14] 林森, 苑玮琦, 魏明月. LST 变换和手部几何特征融合的模糊掌纹识别[J]. 仪器仪表学报, 2013, 34(02): 415-422.
- [15] 陈曦, 于明, 岳峰. 基于局部方向场散列的掌纹快速辨识方法[J]. 科学技术与工程, 2020, 20(18): 7323-7330.
- [16] 张秀峰, 张真林, 谢红. 掌纹 ROI 分割算法的研究与实现[J]. 计算机科学, 2016, 43(S2): 170-173. [33] 郑仕伟, 韩俊刚. 基于深度学习的非接触掌纹识别方法[J]. 微电子学与计算机, 2018, 35(04): 98-102.
- [17] 陈杰, 张雷, 柴钰杰. 基于卷积神经网络的掌纹识别[J]. 软件工程, 2019, 22(10): 7-11.
- [18] 王曦, 盖绍彦, 达飞鹏. 融合几何信息和方向信息的三维掌纹识别方法[J]. 图学学报, 2020, 41(03): 390-398.
- [19] 杨冰, 莫文博, 姚金良. 融合局部特征与深度学习的三维掌纹识别[J]. 浙江大学学报(工学版), 2020, 54(03): 540-545.
- [20] Ungureanu A S, Thavalengal S, Cognard T E. Unconstrained palmprint as a smartphone biometric[J]. IEEE Transactions on Consumer Electronics, 2017, 63(3): 334-342.
- [21] Zhang K, Huang D, Zhang D. An optimized palmprint recognition approach based on image sharpness[J/OL]. Pattern Recognition Letters, 2017, 85: 65-71.
- [22] Michele A, Colin V, Santika D D. Mobilenet convolutional neural networks and support vector machines for palmprint recognition[J/OL]. Procedia Computer Science, 2019, 157: 110-117.
- [23] Zhu J, Zhong D, Luo K. Boosting unconstrained palmprint recognition with adversarial metric learning[J/OL]. IEEE Transactions on Biometrics, Behavior, and Identity Science, 2020, 2(4): 388-398.
- [24] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C] //IEEE cpmfremce on computer Cision and pattern Recognition. IEEE, 2016.